

HakiData

Interroger les statistiques publiques du Sénégal en français, sans SQL

Nom du projet	HakiData
Équipe	Sory Ibrahima Keita & Patrice Dione
Contact	keitasoryibrahima123@gmail.com
Date	12 août 2026
État	Prototype fonctionnel, déployable par Docker Compose

1. Nom du projet

HakiData — plateforme d'analyse conversationnelle des données statistiques publiques.

Le nom associe *haki* — le droit — et la donnée : le droit d'accéder à l'information chiffrée sans passer par un intermédiaire technique.

2. Objectifs et portée du projet

2.1 Constat de départ

L'ANSD publie un volume considérable de données : le catalogue ANADS — son API open data — recense à lui seul 286 enquêtes, dont 71 en accès ouvert. Ces données sont diffusées sous forme de fichiers et de rapports. Les exploiter suppose de savoir télécharger un jeu, ouvrir un tableur, croiser des colonnes — parfois écrire du SQL. La donnée est disponible ; l'usage, lui, reste réservé à ceux qui maîtrisent ces outils.

L'écart n'est donc pas un écart de publication, mais un écart de **réutilisation**. C'est celui que le projet vise.

2.2 Objectif général

Permettre à toute personne — journaliste, étudiant, élu local, agent d'une administration, entrepreneur — de poser une question en français sur les statistiques publiques de l'ANSD et d'obtenir immédiatement un tableau, un graphique ou une carte, ainsi qu'une synthèse écrite, sans écrire une ligne de code.

2.3 Objectifs spécifiques

Objectif	Traduction concrète
Supprimer la barrière technique	Traduire automatiquement une question en français en requête SQL exécutée sur la donnée réelle.
Rendre la donnée lisible	Produire dans le même mouvement le tableau, le graphique adapté, les indicateurs clés et une synthèse rédigée.
Situer la donnée sur le territoire	Reconnaître les régions et départements du Sénégal dans un résultat et les porter sur une carte.
Consommer l'open data de l'ANSD	Interroger directement l'API du catalogue ANADS, plutôt que d'imposer un format propriétaire ou un import manuel.
Garantir la traçabilité	Exposer la requête SQL générée et conserver chaque artefact, pour que tout chiffre puisse être audité.
Préserver la souveraineté	Auto-hébergement : la donnée ne quitte pas l'infrastructure de l'organisation qui l'exploite.

2.4 Portée

Ce que le projet couvre :

- L'interrogation en langage naturel de jeux de données tabulaires, quelle qu'en soit l'origine — catalogue open data de l'ANSD (ANADS), fichier CSV ou Excel, base MySQL ou PostgreSQL.
- La restitution en quatre formes : tableau, requête SQL, visualisation (dont carte), rapport de synthèse.
- Le suivi dans la durée : tableau de bord personnel, indicateurs épinglés, alertes par seuil.
- La gestion des accès : comptes nominatifs, cloisonnement des sources, journal d'audit.

Ce que le projet ne couvre pas :

- La production ou la collecte de données : HakiData exploite l'existant, il ne se substitue pas au producteur.
- Les microdonnées sous licence : leur accès reste soumis à la demande auprès de l'ANSD.
- L'analyse économétrique avancée (modélisation, projections), hors du champ d'un outil de restitution.
- Le traitement de documents non structurés : un rapport PDF n'est pas une source interrogeable.

3. Livrables attendus

Livrable	Contenu	Format
Application web déployée	Plateforme complète : analyse conversationnelle, chat, tableau de bord, alertes, administration	Docker Compose (4 services)
Code source documenté	Backend Python / FastAPI, frontend React / TypeScript, commentaires en français	Dépôt Git, licence ouverte
Connecteur ANADS	Client de l'API open data de l'ANSD, avec normalisation des fiches en colonnes typées	Module Python réutilisable
Répertoire géographique	14 régions, 45 départements et principales villes du Sénégal, avec coordonnées	Module Python + données
Documentation	Guide d'installation, guide des fonctionnalités, description de l'architecture, note d'ouverture aux données publiques	Markdown
Démonstration	Jeu de questions types exécutées sur les données ANSD réelles, avec les résultats produits	Présentation + rapports PDF générés

4. Méthodologie de travail

4.1 Démarche générale

Le développement procède par incréments courts, chacun se terminant sur une fonctionnalité utilisable de bout en bout plutôt que sur une couche technique isolée. Le prototype actuel a été construit ainsi : le pipeline complet — question, SQL, données, graphique, synthèse — a fonctionné avant que l'authentification, le tableau de bord ou les alertes ne soient ajoutés. Cette règle évite l'effet tunnel et rend chaque étape démontrable.

4.2 Conception

L'architecture est en trois niveaux classiques, étendus par un quatrième dédié au modèle de langage. La communication est strictement descendante : le navigateur n'atteint jamais le service applicatif directement, il passe par un serveur Nginx qui assure le chiffrement et le relais des appels.

Niveau	Composant	Responsabilité
Présentation	React 18, TypeScript, Vite, Tailwind CSS	Interface, servie par Nginx en TLS

Niveau	Composant	Responsabilité
Application	Python 3.12, FastAPI, Uvicorn	API REST, pipeline d'analyse, authentification
Données	MySQL 8.0, PostgreSQL, SQLite	Comptes, sources métier, catalogue ANADS importé
Intelligence	Gemini 2.0 Flash ou Groq Llama 3.3 70B	Traduction en SQL, choix du graphique, rédaction

Le principe de conception le plus structurant est que **le modèle de langage ne calcule rien**. Il traduit une intention en requête et met en forme un résultat ; le calcul reste fait par le moteur SQL. C'est ce qui garantit l'exactitude des chiffres et rend l'analyse vérifiable — un point non négociable quand la donnée est statistique et publique.

4.3 Programmation — le pipeline en six étapes

Étape	Traitement	Artefact produit
1. Lecture du schéma	Extraction des tables, colonnes et types de la source	Schéma Markdown
2. Génération SQL	Le modèle rédige la requête à partir de la question et du schéma réel	Fichier .sql
3. Exécution	Requête exécutée sur la source ; rattachement géographique si un territoire est reconnu	CSV + métadonnées
4. Script de visualisation	Choix du type de graphique selon la forme des données	Script Python / Plotly
5. Rendu	Exécution du script, production d'un graphique ou d'une carte interactive	Page HTML
6. Synthèse	Lecture des résultats, rédaction des points clés et des recommandations	Rapport Markdown

Chaque étape laisse un fichier persistant. L'utilisateur peut relire le SQL, le faire valider, retélécharger les données brutes. Rien n'est opaque.

4.4 Outils utilisés

Domaine	Outils	Motif du choix
Langages	Python 3.12, TypeScript 5	Python pour l'écosystème data et les SDK de modèles ; TypeScript pour détecter les erreurs d'interface à la compilation
Backend	FastAPI, Uvicorn, pandas, Plotly	API asynchrone documentée automatiquement ; Plotly produit des graphiques interactifs sans serveur de rendu
Frontend	React 18, Vite, Tailwind CSS	Composants réutilisables, build rapide, cohérence visuelle sans CSS sur mesure
Bases de données	MySQL 8.0, PostgreSQL, SQLite	MySQL pour les comptes ; les deux autres pour les sources métier et les données importées
Modèles de langage	Gemini 2.0 Flash, Groq Llama 3.3 70B	Deux fournisseurs derrière une même interface interne : basculement immédiat en cas de quota atteint
Source de données publiques	API open data ANADS de l'ANSD	Consommer le catalogue officiel directement plutôt que d'imposer un import manuel
Sécurité	TLS, JWT HS256, bcrypt	Chiffrement du transport, jetons signés, mots de passe non réversibles
Déploiement	Docker, Docker Compose, Jenkins	Installation reproductible en une commande ; intégration continue

4.5 Composition et profils de l'équipe

Membre	Profil	Responsabilités sur le projet
Sory Ibrahima Keita	Développement backend et données	Architecture générale, pipeline d'analyse, intégration des modèles de langage, connecteur ANADS, sécurité, déploiement Docker
Patrice Dione	Développement frontend et expérience utilisateur	Interface React, parcours utilisateur, tableau de bord et visualisations, géovisualisation, tests fonctionnels et validation

L'équipe est réduite et polyvalente : chacun relit le travail de l'autre, ce qui remplace une revue formelle par une revue continue. Le travail est suivi dans un dépôt Git unique, avec une chaîne d'intégration continue qui construit et teste à chaque modification.

4.6 Validation

- **Exactitude.** Le SQL généré est affiché systématiquement ; les résultats sont recoupés avec les publications officielles correspondantes.
- **Robustesse.** Le connecteur ANADS a été validé sur les 286 enquêtes réelles du catalogue de l'ANSD, pas sur un jeu fabriqué.
- **Comportement en cas d'échec.** Chaque étape doit échouer de façon explicite — un territoire non reconnu disparaît de la carte mais reste dans le tableau, jamais de valeur inventée.
- **Utilisabilité.** Test du parcours complet par une personne extérieure au développement, sans explication préalable.

5. Impact sur la société et sur l'écosystème des données

5.1 Impact sociétal

Public	Situation actuelle	Avec HakiData
Journalistes et société civile	Lecture de rapports PDF déjà interprétés	Interrogation directe des données de l'ANSD, vérification d'une affirmation en quelques secondes
Collectivités locales	Dépendance aux services centraux pour un chiffre territorial	Consultation autonome des indicateurs de leur région ou département, cartographiés
Étudiants et chercheurs	Temps important consacré à la préparation des données	Accès immédiat à la donnée mise en forme, temps reporté sur l'analyse
Administrations	Cycle long entre la question et le rapport	Réponse immédiate aux questions courantes, agents recentrés sur les analyses complexes
Entreprises et porteurs de projet	Données de marché coûteuses ou inaccessibles	Exploitation des statistiques publiques pour dimensionner une activité

L'effet visé est un déplacement du goulot d'étranglement : aujourd'hui, une question attend la disponibilité de quelqu'un qui sait manipuler la donnée ; demain, elle attend le temps d'une requête. Pour une organisation sans équipe data, cela change la nature des décisions possibles — on peut vérifier une intuition avant de décider, plutôt que de décider puis de justifier.

5.2 Impact sur l'écosystème des données

- **Taux de réutilisation.** Une donnée publiée n'a de valeur que si elle est reprise. En abaissant le coût d'entrée à une question en français, la plateforme élargit mécaniquement le public capable de réutiliser les publications de l'ANSD.
- **Valorisation de l'API open data.** En consommant directement l'API ANADS plutôt qu'en important des fichiers à la main, l'outil rend tangible l'intérêt de la diffusion programmatique et encourage sa généralisation.

- **Retour d'usage au producteur.** Les questions posées constituent une mesure directe de la demande : elles indiquent quels jeux sont attendus, à quelle maille et à quelle fréquence.
- **Culture de la traçabilité.** Exposer systématiquement la requête à côté du résultat installe l'idée qu'un chiffre se vérifie, à rebours des outils qui affichent un nombre sans son calcul.
- **Effet d'entraînement technique.** Le connecteur ANADS est un module autonome, réutilisable par d'autres projets de l'écosystème.

6. Opportunités et perspectives de développement

6.1 Perspectives fonctionnelles

Horizon	Développements
Court terme	Éditeur permettant de corriger la requête avant exécution ; affichage de la progression du pipeline en temps réel ; cartes en aplats par région et département (choroplèthes) ; export Excel ; questions favorites.
Moyen terme	Import direct des microdonnées ANADS en accès ouvert (au-delà des seules métadonnées) ; conversation multi-tours conservant le contexte de l'analyse précédente ; mémoire métier (glossaire et définitions officielles injectés dans chaque requête).
Long terme	Connecteurs vers d'autres portails open data de la sous-région ; exposition des analyses en API pour alimenter d'autres plateformes ; partage d'une analyse par lien protégé ; interface en wolof pour les questions courantes ; extension du répertoire géographique aux communes.

6.2 Opportunités

- **Répliquabilité régionale.** Rien dans l'architecture n'est propre au Sénégal hormis le répertoire géographique. Les instituts de statistique de la sous-région diffusent des données comparables : le même outil s'y transpose en changeant de connecteur.
- **Déploiement institutionnel.** La plateforme peut être hébergée par une administration pour ses propres agents, sur ses propres serveurs, sans que la donnée sorte du périmètre.
- **Usage pédagogique.** Voir la requête SQL produite en regard d'une question en français fait de l'outil un support d'apprentissage de la donnée et du langage SQL.
- **Socle réutilisable.** Le connecteur ANADS peut servir indépendamment de l'interface, dans d'autres chaînes de traitement.
- **Modèle économique soutenable.** Aucune licence propriétaire ; le seul coût variable est l'appel au modèle de langage, marginal à l'échelle d'un service.

6.3 Risques identifiés et parades

Risque	Parade prévue
Requête SQL incorrecte produite par le modèle	Affichage systématique du SQL, éditeur de correction, recoupement avec les publications officielles
Dépendance à un fournisseur de modèle	Deux fournisseurs déjà interchangeables derrière la même interface ; ouverture possible à un modèle auto-hébergé
Accès restreint aux microdonnées	Le projet s'appuie d'abord sur les jeux ouverts et les métadonnées ; l'accès sous licence se demande normalement
Interprétation abusive d'un chiffre	La synthèse cite la source et la période ; les lignes non rattachées restent visibles au lieu d'être masquées
Charge sur les serveurs de l'ANSD	Import ponctuel puis travail sur copie locale, plutôt qu'un appel à chaque question

7. Liste des jeux de données à utiliser

Les jeux ci-dessous ont été identifiés directement dans le catalogue ANADS de l'ANSD — son API open data — interrogée pendant la préparation de cette proposition : 286 enquêtes recensées, dont 71 en accès ouvert (26 en téléchargement direct, 45 en données publiques), 110 sous licence et 15 en accès distant. La colonne « accès » reprend le statut déclaré par le catalogue.

7.1 Sources principales

Jeu de données	Identifiant ANADS	Période	Accès	Usage prévu
Catalogue ANADS complet	API open data	2007-2026	Ouvert	Analyse de l'offre statistique : enquêtes par année, par producteur, par condition d'accès
Enquête nationale sur l'emploi au Sénégal (ENES), trimestrielle	SEN-ANSD-ENES-T 1 à T4	2024-2025	Sous licence	Emploi, chômage et sous-emploi par trimestre et par région
Recensement général de la population et de l'habitat (RGPH-5)	SEN-ANSD-RGPH5-2023-V1.1	2023	Sous licence	Population par région et département : socle de toutes les cartes et des ratios par habitant
Enquête harmonisée sur les conditions de vie des ménages (EHCVM)	SEN-ANSD-EHCVM-2021-2022-V1.0	2021-2022	Sous licence	Conditions de vie, dépenses et pauvreté des ménages
Enquête de suivi de la pauvreté au Sénégal (ESPS)	SEN-ANSD-ESPS-2 011-V2.0	2010-2011	Données publiques	Indicateurs de pauvreté par territoire — jeu ouvert utilisé pour la démonstration
Recensement général des entreprises (RGE)	SEN-ANSD-RGE-20 16-V1.0	2016	Données publiques	Tissu économique par région et par secteur
Suivi de l'impact de la Covid-19 sur les conditions de vie des ménages	SEN-ANSD-SICovid 19CVM1-2020-V1.0	2020	Données publiques	Série de suivi à haute fréquence, utile pour tester les alertes par seuil
Recensement général de la population, de l'habitat, de l'agriculture et de l'élevage (RGPHAE)	SEN-ANSD-RGPHA E-2013-V1.2	2013	Sous licence	Comparaison intercensitaire avec le RGPH-5

7.2 Source complémentaire

Source	Nature	Accès	Usage prévu
Répertoire géographique du Sénégal intégré au projet	14 régions, 45 départements et principales villes, avec coordonnées	Produit par l'équipe, livré avec le code	Rattachement des résultats agrégés par territoire, pour la mise en carte

Les jeux sous licence seront demandés à l'ANSD par la procédure prévue au catalogue. En leur absence, la démonstration repose sur les jeux ouverts et les métadonnées, qui suffisent à établir la chaîne complète.