

Résumé du projet pour le Hackathon

Hakidata « Plateforme d'analyse conversationnelle des données »

I. Contexte et problématique

L'ANSD met à disposition une importante quantité de données statistiques permettant de mieux comprendre les réalités démographiques, sociales et économiques du Sénégal. Cependant, la disponibilité des données ne garantit pas leur exploitation effective. Pour répondre à une question, l'utilisateur peut devoir identifier la source pertinente, rechercher le jeu de données approprié, comprendre sa structure, sélectionner les variables nécessaires, effectuer des traitements et construire des visualisations. Ces étapes peuvent constituer une barrière pour les utilisateurs qui ne maîtrisent pas les outils techniques d'analyse.

II. Présentation de la solution

Hakidata est une plateforme d'analyse conversationnelle multi-source permettant aux utilisateurs techniques ou non techniques d'interroger différentes sources de données en langage naturel. Grâce à l'intelligence artificielle, la plateforme automatise une partie du processus d'analyse, depuis la compréhension de la demande et l'identification des données pertinentes jusqu'à la génération des requêtes, l'exécution des traitements, la production des visualisations et la génération d'insights.

L'objectif est de réduire le temps et la complexité nécessaires pour passer d'une question à une information exploitable, tout en conservant une approche permettant de suivre et de vérifier les traitements réalisés.

III. Fonctionnement et approche méthodologique

Le fonctionnement de Hakidata repose sur une chaîne d'analyse automatisée. L'utilisateur formule sa question en langage naturel. La plateforme analyse la demande, s'appuie sur les schémas et les métadonnées disponibles pour identifier les données et variables pertinentes, puis génère la requête nécessaire à l'analyse. La requête est ensuite exécutée sur la source concernée et les résultats sont transformés en tableaux, graphiques, indicateurs et insights.

L'architecture multi-source permet d'exploiter des bases de données relationnelles, des fichiers structurés, des APIs et des données ouvertes. Dans le contexte de l'ANSD, elle est notamment destinée à intégrer les données ouvertes accessibles via API et le catalogue ANADS, tout en conservant la possibilité d'exploiter des fichiers CSV/Excel ainsi que des bases MySQL et PostgreSQL.

Par exemple, à la question « Quelles régions du Sénégal ont connu la plus forte croissance démographique ? », Hakidata identifie les données nécessaires, génère la requête permettant de calculer et de comparer l'évolution de la population par région, puis restitue les résultats sous forme de visualisation et d'insights.

IV. Utilisateurs et valeur ajoutée

Hakidata s'adresse notamment aux agents et analystes de données, chercheurs, décideurs publics et utilisateurs non techniques souhaitant exploiter des données statistiques sans devoir maîtriser l'ensemble des outils techniques nécessaires à leur traitement.

L'utilisation de l'intelligence artificielle permet d'automatiser plusieurs étapes de l'analyse et ainsi de réduire les manipulations manuelles et le temps nécessaire pour obtenir un premier résultat. La

précision des résultats repose toutefois sur les données sources, la structure des données, la requête générée et les contrôles effectués ; Hakidata vise donc à associer automatisation, traçabilité et vérification plutôt qu'à présenter l'IA comme une garantie absolue de précision.

V. Contribution à l'écosystème des données statistiques de l'ANSD

Dans le contexte des données statistiques publiques de l'ANSD, Hakidata constitue une couche d'exploitation complémentaire aux dispositifs de diffusion existants. Il facilite l'accès, l'utilisation et la valorisation des données en permettant de passer plus rapidement d'une question formulée en langage naturel à une analyse structurée, visualisée et directement exploitable.

La plateforme contribue notamment à favoriser la réutilisation des données, à produire des indicateurs et analyses dérivés, à faciliter le croisement de sources et à rendre les résultats plus accessibles à des profils techniques comme non techniques.

VI. Équipe

L'équipe est composée d'étudiants en Licence 2 Big Data à Dakar Institute of Technology (DIT), avec des compétences complémentaires en développement, Data Engineering, bases de données, intelligence artificielle, traitement des données et visualisation.